

Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados e EDB-022

Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Atividade 1:

Atividade 1 – Ingestão e ETL com ferramenta visual

- Utilizar uma ferramenta visual para ingestão e tratamento de dados. Qualquer ferramenta visual pode ser utilizado, sendo algumas das sugestões:
 - Kettle (Pentaho Data Integration) – Apache Hop
 - Talend
 - Knime
 - Pode ser utilizado também laboratório em cloud fornecido pela programa na AWS com a ferramenta visual do Glue
- Realizar a ingestão de todas as bases de dados em um banco de dados relacional open source. Pode ser utilizado qualquer banco de dados sendo algumas sugestões:
 - MySQL
 - PostgreSQL
 - ClickHouse
- Gerar uma tabela final com os dados tratados e unidos.
 - O tratamento de dados deve ser realizado através da ferramenta de ETL

Container PostgreSQL criado e rodando via Docker:


```
(base) camil@MacBook-Air eEDB-022 % docker ps
CONTAINER ID   IMAGE          COMMAND                  CREATED        STATUS
PORTS         NAMES
e82895d31a65   postgres      "docker-entrypoint.s..." About a minute ago Up About a minute
0.0.0.0:5432->5432/tcp, [::]:5432->5432/tcp   pg-eedb022
(base) camil@MacBook-Air eEDB-022 %
```

Conexão validada ao banco PostgreSQL via psql dentro do container Docker:

```
(base) camil@MacBook-Air eEDB-022 % docker exec -it pg-eedb022 psql -U camila -d eedb022
psql (18.4 (Debian 18.4-1.pgdg13+1))
Type "help" for help.

eedb022=#
```

Apache Hop instalado e funcional:




Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022


Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Projeto eEDB-022 configurado no Apache Hop, apontando para o repositório do curso:



Conexão com PostgreSQL configurada e testada com sucesso no Apache Hop:




Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022


Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Criando pipeline no Hop:



Adicionado transform de leitura de arquivo texto no pipeline de ingestão dos Bancos:



Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022

Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Arquivo EnquadramentoInicia_v2.tsv lido pelo Hop:

The screenshot shows the 'Text file input' transform configuration in Hop. The 'Transform name' is 'ler_bancos_tsv'. The 'Fields' tab is selected, showing a schema definition table with columns: #, Name, Type, Format, Position, Length, Precision, Currency, Decimal, Group, Null if, Default, Trim type, and Repe. The table contains three rows of data.

#	Name	Type	Format	Position	Length	Precision	Currency	Decimal	Group	Null if	Default	Trim type	Repe:
1	Segmento	String			2		\$	.	,	-		none	N
2	CNPJ	Integer	#		15	0	\$	,	.	-		none	N
3	Nome	String			122		\$	.	,	-		none	N

OBS: Possível erro encontrado. CNPJs estão aparecendo sem zeros a esquerda... CNPJ mantido no formato original por enquanto. A padronização com zeros à esquerda será aplicada na etapa de tratamento e join final.

The screenshot shows the 'Examine preview data' window in Hop, displaying the first 14 rows of the transform output. The window title is 'Examine preview data'. The subtitle is 'Rows of transform ler_bancos_tsv (1000 rows)'. The data is presented in a table with columns: #, Segmento, CNPJ, and Nome.

#	Segmento	CNPJ	Nome
1	S1	0	BANCO DO BRASIL - PRUDENCIAL
2	S1	60746948	BRABESCO - PRUDENCIAL
3	S1	30306294	BTG PACTUAL - PRUDENCIAL
4	S1	360305	CAIXA ECONOMICA FEDERAL - PRUDENCIAL
5	S1	60872504	ITAU - PRUDENCIAL
6	S1	90400888	SANTANDER - PRUDENCIAL
7	S2	92702067	BANRISUL - PRUDENCIAL
8	S2	7237373	BANCO DO NORDESTE DO BRASIL S.A. - PRUDENCIAL
9	S2	33657248	BNDDES - PRUDENCIAL
10	S2	33479023	CITIBANK - PRUDENCIAL
11	S2	33987793	CREDIT SUISSE - PRUDENCIAL
12	S2	58160789	SAFRA - PRUDENCIAL
13	S2	59588111	VOTORANTIM - PRUDENCIAL
14	S3	28195667	ABC-BRASIL - PRUDENCIAL


Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados e EDB-022


Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Primeira tabela criada no banco via Hop:



Erro após primeira execução: Motivo: É necessário aumentar o tamanho da coluna Nome na tabela



Solução:

```
((base) camil@MacBook-Air ~ % PGPASSWORD=eedb022 psql -h localhost -p 5433 -U camila -d eedb022 -c "ALTER TABLE stg_bancos ALTER COLUMN nome TYPE VARCHAR(255);"
ALTER TABLE
(base) camil@MacBook-Air ~ %
```

Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados e EDB-022

Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Sucesso:

The screenshot displays the Hop Data Platform interface. On the left, a pipeline diagram shows a data source 'ler_bancos_tsv' connected to a 'Table output' target. Both components have green checkmarks indicating successful execution. The right pane shows the 'Logging' tab with a detailed log of the pipeline's execution. The log entries, timestamped 2026/08/03 19:28:19 and 2026/08/03 19:28:20, show the pipeline opening, launching, starting execution, connecting to the database [pg_eedb022], opening the file, finishing processing (1=1475, O=0, R=0, W=1474, U=1, E=0), and finally completing the pipeline with a duration of 0.167 seconds.

```
2026/08/03 19:28:19 [Basic] Hop - Pipeline opened.
2026/08/03 19:28:19 [Basic] Hop - Launching pipeline [pipeline_ingestao_bancos]...
2026/08/03 19:28:19 [Basic] Hop - Started executing pipeline 'pipeline_ingestao_bancos'.
2026/08/03 19:28:20 [Basic] pipeline_ingestao_bancos - Executing this pipeline using the Local Pipeline Engine with run configuratio
2026/08/03 19:28:20 [Basic] pipeline_ingestao_bancos - Execution started for pipeline [pipeline_ingestao_bancos]
2026/08/03 19:28:20 [Basic] Table output.0 - Connected to database [pg_eedb022] (commit=1000)
2026/08/03 19:28:20 [Basic] ler_bancos_tsv.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20d
2026/08/03 19:28:20 [Basic] ler_bancos_tsv.0 - Finished processing (I=1475, O=0, R=0, W=1474, U=1, E=0)
2026/08/03 19:28:20 [Basic] Table output.0 - Finished processing (I=0, O=1474, R=1474, W=1474, U=0, E=0)
2026/08/03 19:28:20 [Basic] pipeline_ingestao_bancos - Pipeline duration : 0.167 seconds [ 0.167" ]
2026/08/03 19:28:20 [Basic] Hop - Pipeline 'pipeline_ingestao_bancos' completed.
2026/08/03 19:28:20 [Basic] pipeline_ingestao_bancos - Execution finished on a local pipeline engine with run configuration 'local'
```

Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022


Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Diferente da fonte de Bancos, os dados de Empregados vieram divididos em dois arquivos (glassdoor_consolidado_join_match_v2.csv e glassdoor_consolidado_join_match_less_v2.csv), resultado de duas estratégias diferentes de casamento com a base de Bancos: o primeiro casa por Segmento + Nome, o segundo por CNPJ + Nome (usado como alternativa para os registros que não bateram pelo nome). Como as duas fontes têm estrutura quase idêntica, mas cada uma possui uma coluna que a outra não tem (Segmento em um, CNPJ no outro), o pipeline lê os dois arquivos separadamente (ler_empregados_v2 e ler_empregados_less_v2), padroniza a estrutura adicionando a coluna faltante como vazia em cada fluxo

(add_cnpj_vazio e add_segmento_vazio), reordena os campos

(ordenar_campos_v2 e ordenar_campos_less_v2) para garantir a mesma sequência de colunas nos dois lados, une os fluxos (unir_empregados) via Append streams, empilhando as duas fontes num único conjunto de dados, e por fim grava tudo no PostgreSQL, na tabela stg_empregados.




Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022


Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Segunda tabela criada no banco via Hop:



Pipeline de ingestão de Empregados executado com sucesso, unificando 39 registros de duas fontes distintas na tabela stg_empregados (chocantemente sem erros)



Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022


Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Diferente das fontes anteriores, os dados de Reclamações vieram divididos em oito arquivos trimestrais (2021 e 2022), todos com a mesma estrutura de colunas. O transform ler_reclamacoes usa wildcard para ler automaticamente todos os arquivos .csv da pasta Dados/Reclamacoes, excluindo o arquivo 2022_tri_02_nao_ha_dados.csv, identificado como vazio (0 registros) e sem relevância para a ingestão. Como os sete arquivos válidos compartilham a mesma estrutura, o próprio Text file input já consolida todos eles num único fluxo de dados, sem necessidade de um passo de união como fizemos com Empregados. Em seguida, o transform gravar_reclamacoes grava o resultado consolidado na tabela stg_reclamacoes do PostgreSQL.



Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli



Results of the SQL statements

The SQL statements had the following results

SQL executed: CREATE TABLE stg_reclamacoes

Ano	Trimestre	Categoria	Tipo	CNPJ_IF	Instituição financeira	Índice	Quantidade de reclamações reguladas	Quantidade de reclamações não reguladas	Quantidade total de reclamações	Quantidade total de clientes CCS e SCR	Quantidade de clientes CCS	Quantidade de clientes SCR
2019	1	Reclamação	Reclamação	12345678901234567890	Banco do Brasil	100	10	5	15	100	50	50

1 SQL statements executed

OK Cancel

The screenshot displays the Apache Hop IDE interface. On the left, a diagram of a data pipeline is visible, featuring two main components: 'ler_reclamacoes' (read reclamations) and 'gravar_reclamacoes' (save reclamations). The 'ler_reclamacoes' component is connected to a database icon, and the 'gravar_reclamacoes' component is connected to a file icon. On the right, the 'Logging' tab is active, showing a detailed log of the pipeline's execution. The log entries are timestamped '2026/08/04 09:43:28' and include the following information:

- Basic:** Hop - Pipeline opened. Hop - Launching pipeline [pipeline_ingestao_reclamacoes]... Hop - Started executing pipeline 'pipeline_ingestao_reclamacoes'.
- Basic:** pipeline_ingestao_reclamacoes - Executing this pipeline using the Local Pipeline Engine with run configuration 'local'
- Basic:** pipeline_ingestao_reclamacoes - Execution started for pipeline [pipeline_ingestao_reclamacoes]
- Basic:** gravar_reclamacoes.0 - Connected to database [pg_eedb022] (commit:1000)
- Basic:** ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2021/ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2021/ler_reclamacoes.0 - Unexpected error
- Error:** org.apache.hop.core.exception.HopException: ler_reclamacoes.0 - Error converting line
- Error:** ler_reclamacoes.0 - Couldn't parse field [Integer(15)] with value [], format [#] on data row [215].
- Error:** ler_reclamacoes.0 - Unexpected conversion error while converting value [Quantidade_total_de_clientes__CCS_e_SCR String(15)] to an Integer
- Error:** ler_reclamacoes.0 - Quantidade_total_de_clientes__CCS_e_SCR String(15) : couldn't convert String to Integer
- Error:** ler_reclamacoes.0 - Quantidade_total_de_clientes__CCS_e_SCR String(15) : couldn't convert String to number : non-numeric character in input
- Error:** ler_reclamacoes.0 - at org.apache.hop.pipeline.transforms.fileinput.text.TextFileInputUtils.convertLineToRow(TextFileInputUtils.java:586)
- Error:** ler_reclamacoes.0 - at org.apache.hop.pipeline.transforms.fileinput.text.TextFileInputUtils.convertLineToRow(TextFileInputUtils.java:318)
- Error:** ler_reclamacoes.0 - at org.apache.hop.pipeline.transforms.fileinput.text.TextFileInputReader.readLineToRow(TextFileInputReader.java:355)
- Error:** ler_reclamacoes.0 - at org.apache.hop.pipeline.transforms.fileinput.text.TextFileInputProcessRow(TextFileInput.java:208)
- Error:** ler_reclamacoes.0 - at org.apache.hop.pipeline.transform.RunThread.run(RunThread.java:54)
- Error:** ler_reclamacoes.0 - at java.base/java.lang.Thread.run(Thread.java:1583)
- Error:** ler_reclamacoes.0 - Caused by: org.apache.hop.core.exception.HopException: Couldn't parse field [Integer(15)] with value [], format [#] on data row [215].
- Error:** ler_reclamacoes.0 - Unexpected conversion error while converting value [Quantidade_total_de_clientes__CCS_e_SCR String(15)] to an Integer
- Error:** ler_reclamacoes.0 - Quantidade_total_de_clientes__CCS_e_SCR String(15) : couldn't convert String to Integer
- Error:** ler_reclamacoes.0 - Quantidade_total_de_clientes__CCS_e_SCR String(15) : couldn't convert String to number : non-numeric character in input
- Error:** ler_reclamacoes.0 - at org.apache.hop.pipeline.transforms.fileinput.text.TextFileInputUtils.convertLineToRow(TextFileInputUtils.java:485)
- Error:** ler_reclamacoes.0 - 5 more...
- Error:** ler_reclamacoes.0 - Caused by: org.apache.hop.core.exception.HopException: Couldn't parse field [Integer(15)] with value [], format [#] on data row [215].

Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022

Atividade 1


Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

OBS: Dois problemas identificados: a coluna Categoria tinha valores mais longos (ex: "Demais bancos e financeiras") do que o tamanho VARCHAR(16) definido pela detecção automática de tipos, e algumas colunas numéricas de quantidade continham espaços em branco em vez de valores, impedindo a conversão para Integer. Os problemas foram corrigidos aumentando a coluna Categoria para VARCHAR(50) diretamente no PostgreSQL, e ajustando o Trim Type dos campos numéricos no Hop para tratar espaços em branco corretamente antes da conversão.

```
ERROR: column "categoria" of relation "stg_reclamacoes" does not exist
((base) camil@MacBook-Air ~ % PGPASSWORD=eedb022 psql -h localhost -p 5433 -U camila -d eedb022 -c "ALTER TABLE stg_reclamacoes ALTER COLUMN categoria TYPE VARCHAR(50);"
ALTER TABLE
(base) camil@MacBook-Air ~ %
```

Aparentemente corrigido, vamos executar de novo pra testar...

Erro de novo:



The screenshot shows the Hop Studio interface with a pipeline named 'pipeline_ingestao_reclamacoes'. The pipeline is configured to use a local pipeline engine. The error log shows a 'HopException' with the message 'Couldn't parse field [Number(15, 1)] with value [2.055,01], format [#.#] on data row [288]'. The error is caused by a non-numeric character found at position 2 for the value [2.055,01]. The error log also shows the pipeline configuration and the data source being used.

OBS: A coluna Índice (e outras colunas do tipo Number) continha valores no padrão brasileiro (ex: "2.055,01", com ponto como separador de milhar e vírgula como decimal), enquanto o Hop estava configurado para interpretar números no padrão americano (ponto decimal, vírgula de milhar). A correção envolveu ajustar as configurações de Decimal e Group dos campos numéricos no Text file input, invertendo os separadores para o formato brasileiro correto.

Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022

Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Erro de novo após correção:

2026/08/04 09:59:30 [Basic] Hop - Pipeline opened.
2026/08/04 09:59:30 [Basic] Hop - Launching pipeline [pipeline_ingestao_reclamacoes]...
2026/08/04 09:59:30 [Basic] Hop - Started executing pipeline 'pipeline_ingestao_reclamacoes'.
2026/08/04 09:59:30 [Basic] pipeline_ingestao_reclamacoes - Executing this pipeline using the Local Pipeline Engine with run configuration 'local'
2026/08/04 09:59:30 [Basic] pipeline_ingestao_reclamacoes - Execution started for pipeline [pipeline_ingestao_reclamacoes]
2026/08/04 09:59:30 [Basic] gravar_reclamacoes.0 - Connected to database [pg_eedb022] (commit=1000)
2026/08/04 09:59:30 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2021.
2026/08/04 09:59:30 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2021.
2026/08/04 09:59:30 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2021.
2026/08/04 09:59:30 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2022.
2026/08/04 09:59:30 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2022.
2026/08/04 09:59:30 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2022.
2026/08/04 09:59:30 [Basic] ler_reclamacoes.0 - Finished processing (I=925, O=0, R=0, W=918, U=7, E=0)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - Unexpected batch update error: committing the database connection.
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - org.apache.hop.core.exception.HopDatabaseBatchException:
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - Batch entry 329 INSERT INTO stg_reclamacoes (Ano, Trimestre, Categoria, Tipo, CNPJ_JF, Instituição_financeira,
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.apache.hop.core.database.Database.createHopDatabaseBatchException(Database.java:1360)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.apache.hop.core.database.Database.emptyAndCommit(Database.java:1348)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.apache.hop.pipeline.transforms.tableoutput.TableOutput.emptyAndCommitBatchBuffers(TableOutput.java:1156)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.apache.hop.pipeline.transforms.tableoutput.TableOutput.dispose(TableOutput.java:96)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.apache.hop.pipeline.transform.RunThread.run(RunThread.java:1683)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at java.base/java.lang.Thread.run(Thread.java:1683)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - Caused by: java.sql.BatchUpdateException: Batch entry 329 INSERT INTO stg_reclamacoes (Ano, Trimestre, Cat
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.jdbc.BatchResultHandler.handleError(BatchResultHandler.java:168)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.core.ResultHandlerDelegate.handleError(ResultHandlerDelegate.java:52)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.core.v3.QueryExecutorImpl.processResults(QueryExecutorImpl.java:2590)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.core.v3.QueryExecutorImpl.processResults(QueryExecutorImpl.java:2322)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.core.v3.QueryExecutorImpl.flushAndCommit(QueryExecutorImpl.java:1628)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.core.v3.QueryExecutorImpl.sendQuery(QueryExecutorImpl.java:1653)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.core.v3.QueryExecutorImpl.execute(QueryExecutorImpl.java:660)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.jdbc.PgStatement.internalExecuteBatch(PgStatement.java:900)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.jdbc.PgStatement.executeBatch(PgStatement.java:924)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.jdbc.PgPreparedStatement.executeBatch(PgPreparedStatement.java:1778)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.apache.hop.core.database.Database.emptyAndCommit(Database.java:1335)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - ... 4 more
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - Caused by: org.postgresql.util.PSQLException: ERROR: value too long for type character varying(50)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.core.v3.QueryExecutorImpl.receiveErrorResponse(QueryExecutorImpl.java:2904)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - at org.postgresql.core.v3.QueryExecutorImpl.processResults(QueryExecutorImpl.java:2589)
2026/08/04 09:59:30 [Error] gravar_reclamacoes.0 - 12 more
2026/08/04 09:59:30 [Basic] Hop - Stopped processing pipeline 'pipeline_ingestao_reclamacoes'.
2026/08/04 09:59:30 [Basic] gravar_reclamacoes.0 - Finished processing (I=0, O=0, R=0, W=918, U=0, E=1)
2026/08/04 09:59:30 [Basic] pipeline_ingestao_reclamacoes - Pipeline duration : 0.204 seconds [0.204 s]

OBS: A leitura dos arquivos já estava totalmente correta (nenhum erro de conversão), mas a gravação falhou porque a coluna Categoria continha um valor ainda maior do que o limite ajustado anteriormente ("Demais Bancos, Financeiras e Instituições de Pagamento", 56 caracteres, excedendo o VARCHAR(50)). A correção foi aumentar novamente o tamanho da coluna no PostgreSQL, dessa vez para VARCHAR(100), com folga suficiente para comportar variações futuras nesse campo.

Corrigido, vamos executar de novo

```
(base) camil@MacBook-Air ~ % PGPASSWORD=eedb022 psql -h localhost -p 5433 -U camila -d eedb022 -c "ALTER TABLE stg_reclamacoes ALTER COLUMN categoria TYPE VARCHAR(100);"
ALTER TABLE
(base) camil@MacBook-Air ~ %
```

Sucesso:

2026/08/04 10:03:38 [Basic] Hop - Pipeline opened.
2026/08/04 10:03:38 [Basic] Hop - Launching pipeline [pipeline_ingestao_reclamacoes]...
2026/08/04 10:03:38 [Basic] Hop - Started executing pipeline 'pipeline_ingestao_reclamacoes'.
2026/08/04 10:03:38 [Basic] pipeline_ingestao_reclamacoes - Executing this pipeline using the Local Pipeline Engine with run configuration 'local'
2026/08/04 10:03:38 [Basic] pipeline_ingestao_reclamacoes - Execution started for pipeline [pipeline_ingestao_reclamacoes]
2026/08/04 10:03:38 [Basic] gravar_reclamacoes.0 - Connected to database [pg_eedb022] (commit=1000)
2026/08/04 10:03:38 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2021.
2026/08/04 10:03:38 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2021.
2026/08/04 10:03:38 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2021.
2026/08/04 10:03:38 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2022.
2026/08/04 10:03:38 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2022.
2026/08/04 10:03:38 [Basic] ler_reclamacoes.0 - Opening file: file:///Users/camil/Documents/pós%20graduação/ingestão%20de%20dados/Dados/Reclamacoes/2022.
2026/08/04 10:03:38 [Basic] ler_reclamacoes.0 - Finished processing (I=925, O=0, R=0, W=918, U=7, E=0)
2026/08/04 10:03:38 [Basic] gravar_reclamacoes.0 - Finished processing (I=0, O=918, R=918, W=918, U=0, E=0)
2026/08/04 10:03:38 [Basic] pipeline_ingestao_reclamacoes - Pipeline duration : 0.187 seconds [0.187 s]
2026/08/04 10:03:38 [Basic] Hop - Pipeline 'pipeline_ingestao_reclamacoes' completed.
2026/08/04 10:03:38 [Basic] pipeline_ingestao_reclamacoes - Execution finished on a local pipeline engine with run configuration 'local'

Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022

Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Criação da pipeline final:

Primeiro vamos ler a tabela de reclamações, que vai ser nossa fato (por ser a maior de todas)

Table input

Transform name

Connection

Load SQL from file

SQL

```
SELECT * FROM stg_reclamacoes
```

Line 1 Column 30

Replace variables in script ☐

Insert data from transform

Execute for each row ☐

Limit size


Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022

Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Agora vamos padronizar os CNPJs (estão sem zeros a esquerda e isso pode dar problema pra gente depois):



Formula

Transform name: padronizar_cnpj_reclamacoes


Fields:

# ^	New field	Formula	Value type	Length
1	CNPJ_padronizado	RIGHT(CONCATENATE("00000000",[cnpj_if]),8)	String	

Buttons: ? Help, OK, Cancel

OBS: Gruda oito zeros na frente do CNPJ (ex: "360305" vira "00000000360305"), depois pega só os últimos 8 caracteres daquele texto todo (00360305), que é exatamente o resultado que queremos.

O mesmo processo foi realizado para todas as tabelas:



Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados e EDB-022

Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Com os CNPJs padronizados, uso dois blocos de Stream lookup em sequência: o primeiro busca em Bancos o segmento e o nome da instituição correspondente a cada reclamação; o segundo, a partir desse resultado já enriquecido, busca em Empregados as notas de avaliação do Glassdoor daquele mesmo banco. No final, gravo tudo junto (dados de reclamações, identificação do banco e notas dos funcionários) na tabela final `tb_final_bancos_reclamacoes` no PostgreSQL.





Tabela que vai armazenar os resultados finais foi criada no banco:



Curso de Especialização em Big Data – Escola Politécnica da USP

Ingestão de Dados eEDB-022

Atividade 1

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Tabela final criada com sucesso:

Rows of transform "public"tb_final_bancos_reclamacoes (100 rows)

#	# ano	trimestre	categoria	tipo	cnpj_if	instituição_financeira	# quantidade_de_reclamações_reguladas_procedentes	# quantidade_de_reclamações_não_reguladas_procedentes
2	2021	1º	Grupo Secundário	Conglomerado	<cnpj>	AGIBANK (conglomerado)		58
3	2021	1º	Grupo Secundário	Banco/financeira	36321990	AGORACRED S/A SOCIEDADE DE CRÉDITO, FINANCIAMENTO E INVESTIMENTO		3
4	2021	1º	Grupo Secundário	Banco/financeira	27214112	AL5 S.A. CRÉDITO, FINANCIAMENTO E INVESTIMENTO		1
5	2021	1º	Grupo Secundário	Conglomerado	<cnpj>	ALFA (conglomerado)		14
6	2021	1º	Grupo Secundário	Conglomerado	<cnpj>	ANDBANK (conglomerado)		0
7	2021	1º	Grupo Secundário	Banco/financeira	03532415	BANCO ABN AMRO S.A.		0
8	2021	1º	Grupo Secundário	Banco/financeira	54403563	BANCO ARBI S.A.		1
9	2021	1º	Grupo Secundário	Banco/financeira	02992446	BANCO CNH INDUSTRIAL CAPITAL S.A.		0
10	2021	1º	Grupo Secundário	Banco/financeira	08357240	BANCO CSF S.A.		165
11	2021	1º	Grupo Secundário	Banco/financeira	04902979	BANCO DA AMAZONIA S.A.		4
12	2021	1º	Grupo Secundário	Banco/financeira	10690848	BANCO DA CHINA BRASIL S.A.		0
13	2021	1º	Grupo Secundário	Banco/financeira	05040481	BANCO DE LAGE LANDEN BRASIL S.A.		0
14	2021	1º	Grupo Secundário	Banco/financeira	92874270	BANCO DIGIMAIS S.A.		143
15	2021	1º	Grupo Secundário	Banco/financeira	27098060	BANCO DIGIO S.A.		40
16	2021	1º	Grupo Secundário	Banco/financeira	13009717	BANCO DO ESTADO DE SERGIPE S.A.		11
17	2021	1º	Grupo Secundário	Banco/financeira	04913711	BANCO DO ESTADO DO PARÁ S.A.		39
18	2021	1º	Grupo Secundário	Banco/financeira	07237373	BANCO DO NORDESTE DO BRASIL S.A.		19
19	2021	1º	Grupo Secundário	Banco/financeira	58616418	BANCO FIBRA S.A.		1
20	2021	1º	Grupo Secundário	Banco/financeira	62237425	BANCO FIDIS S/A		0