

Atividade 5 — Orquestração, Qualidade e Metadados

Curso de Especialização em Big Data — Escola Politécnica da USP Ingestão de Dados eEDB-022

Grupo: Camila Faleiros, Fernando Luiz, Guilherme Sergio e Lucca Tomazeli

Projeto completo disponível no GitHub >> https://github.com/LuccaTomazeli/eEDB-022/tree/main/atividade_05

1. Objetivo

A Atividade 5 tem como objetivo integrar e orquestrar os processos desenvolvidos na Atividade 04, utilizando ferramentas voltadas para:

- Orquestração de pipelines: Apache Airflow
- Transformação de dados: dbt
- Qualidade de dados: Great Expectations
- Banco de dados: PostgreSQL
- Catálogo e metadados: DataHub
- Persistência/entrega dos dados: Parquet

A solução foi construída utilizando containers Docker, permitindo reproduzir o ambiente de execução localmente.

2. Tecnologias utilizadas

Tecnologia	Finalidade
Docker	Containerização do ambiente
Docker Compose	Orquestração dos containers
Apache Airflow	Orquestração do pipeline
PostgreSQL	Armazenamento dos dados
Python	Scripts de ingestão, transformação e validação
dbt	Transformação e modelagem
Great Expectations	Validação da qualidade dos dados
DataHub	Catálogo e gerenciamento de metadados

Tecnologia	Finalidade
Parquet	Formato de armazenamento dos dados finais
Git/GitHub	Versionamento do projeto

5. Banco de dados

Foi utilizado um PostgreSQL dedicado ao pipeline da Atividade 5.

Banco: eedb022_a5

Schemas: raw trusted delivery

O fluxo de dados é:



As principais tabelas/modelos são:

Trusted trusted.trusted_bancos trusted.trusted_empregados trusted.trusted_reclamacoes
 Delivery delivery.delivery_final

Estrutura das camadas

5.1 Raw

Dados carregados das fontes com mínima transformação.

Principais tabelas:

- raw.bancos
- raw.empregados
- raw.reclamacoes
- raw.depara_bcb

5.2 Trusted

Dados tratados e preparados para consumo.

Principais tabelas:

- trusted.trusted_bancos
- trusted.trusted_empregados
- trusted.trusted_reclamacoes

5.3 Delivery

Camada final consolidada para análise:

- delivery.delivery_final

6. DAG principal

O pipeline principal é o `pipeline_atividade_05`, executado no Airflow com o seguinte fluxo:

```
graph TD; ingest_raw --> depara_bcb; depara_bcb --> dbt_run; dbt_run --> quality_check; quality_check --> export_parquet;
```

7. Descrição das etapas

ingest_raw: realiza a ingestão dos arquivos para a camada raw.

depara_bcb: aplica o relacionamento/de-para necessário aos dados do Banco Central.

dbt_run: executa os modelos de transformação do projeto dbt.

quality_check: executa as validações de qualidade dos dados.

export_parquet: exporta os dados finais para o formato Parquet.

8. DBT

O projeto dbt está organizado nos seguintes modelos:

models/

└─ delivery_final.sql

└─ trusted_bancos.sql

└─ trusted_empregados.sql

└─ trusted_reclamacoes.sql

Os modelos principais são materializados como tabelas no PostgreSQL.

O delivery_final consolida informações das tabelas trusted e representa a camada final de consumo.

9. Qualidade de dados

O pipeline utiliza Great Expectations para validar os dados antes da exportação final.

Entre os controles aplicados estão validações de estrutura, preenchimento e consistência dos dados utilizados pelo pipeline.

10. Exportação Parquet

Após a execução das validações, os dados da camada final são exportados para arquivos Parquet, permitindo armazenamento em formato colunar e adequado para uso analítico.

11. DataHub

O DataHub 1.7.0 foi utilizado para catalogação dos ativos e registro dos relacionamentos entre os conjuntos de dados.

Foi realizada a ingestão dos metadados do projeto dbt a partir de:

/dbt/target/manifest.json

/dbt/target/run_results.json

A configuração utilizada está no arquivo:

atividade_05/dbt/datahub_dbt.yml

O catálogo contém os modelos dbt e seus relacionamentos de lineage.

12. Lineage principal

O relacionamento principal da atividade é:

```
trusted_bancos
  \
  \
trusted_empregados ---> delivery_final
  /
  /
trusted_reclamacoes
```

Ou, de forma simplificada:

PostgreSQL Trusted

```
├─ trusted_bancos
├─ trusted_empregados
├─ trusted_reclamacoes
  |
  v
dbt.delivery_final
```

Também foi registrada a lineage física entre os datasets PostgreSQL correspondentes.

13. Acessos locais

DataHub

<http://localhost:9002>

Airflow


<http://localhost:8080>

14. Reprodução

1. Verificar Versão Docker e Docker Compose

docker --version


docker compose version



```
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker --version
Docker version 29.3.1, build c2be9cc
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose version
Docker Compose version v5.1.1
```

2. Baixar imagem do Airflow

pull apache/airflow:3.3.1



```
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker pull apache/airflow:3.3.1
3.3.1: Pulling from apache/airflow
039e6f9f9752: Pulling fs layer
a2a0c68a68d7: Pulling fs layer
4f4fb700ef54: Pulling fs layer
3b7173148a6e: Pulling fs layer
f4258d0ae892: Pulling fs layer
ee210ce773e3: Pulling fs layer
45963fa80498: Pulling fs layer
f4258d0ae892: Downloading 27.26MB/30.07MB
4f4fb700ef54: Pull complete
ebb190f530cc: Pull complete
8852949e363b: Pull complete
c9e9ea7b3029: Pull complete
5dbf672c463d: Pull complete
c1df3d4e0141: Pull complete
e5bfe00653e5: Pull complete
c3917b4e1c86: Pull complete
e73432bd420a: Pull complete
ba2bedf94db8: Pull complete
2c09eaeef2069: Pull complete
a0d7b93268f1: Pull complete
aaf568640270: Download complete
Digest: sha256:0c4bcc0370e526de1b7892a3bf4343d260c6c82359c66f77155b53cd773d6339
Status: Downloaded newer image for apache/airflow:3.3.1
```

3. Configurar arquivo docker-compose.yml

docker compose config

```
Problems Output Debug Console Terminal ... powershell - atividade_05 [A] + v [ ] [X] ... [ ] [ ]

PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose config
networks:
  default: null
restart: unless-stopped
volumes:
  - type: volume
    source: postgres_data
    target: /var/lib/postgresql/data
    volume: {}
networks:
  default:
    name: atividade_05_default
volumes:
  postgres_data:
    name: atividade_05_postgres_data
```

4. Subir o Airflow

`docker compose up -d`

`docker compose ps`

```
Problems Output Debug Console Terminal ... powershell - atividade_05 [A] + v [ ] [X] ... [ ] [ ]

PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose config
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose up -d
[+] up 25/25
✓ Image postgres:17 Pulled 147.0s
✓ Network atividade_05_default Created 0.9s
✓ Volume atividade_05_postgres_data Created 0.5s
✓ Container airflow-postgres Healthy 74.8s
✓ Container airflow-init Exited 114.2s
✓ Container airflow-dag-processor Started 119.6s
✓ Container airflow-triggerer Started 121.0s
✓ Container airflow-apiserver Started 121.4s
✓ Container airflow-scheduler Started 116.9s
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose ps
NAME                IMAGE                COMMAND                SERVICE
CREATED            STATUS              PORTS
airflow-apiserver   apache/airflow:3.3.1 "/usr/bin/dumb-init ..." airflow-apiserver
3 minutes ago      Up About a minute   0.0.0.0:8080->8080/tcp, [::]:8080->8080/tcp
airflow-dag-processor apache/airflow:3.3.1 "/usr/bin/dumb-init ..." airflow-dag-processor
3 minutes ago      Up About a minute   8080/tcp
airflow-postgres     postgres:17          "docker-entrypoint.s..." postgres
3 minutes ago      Up 3 minutes (healthy) 5432/tcp
airflow-scheduler    apache/airflow:3.3.1 "/usr/bin/dumb-init ..." airflow-scheduler
3 minutes ago      Up About a minute   8080/tcp
airflow-triggerer    apache/airflow:3.3.1 "/usr/bin/dumb-init ..." airflow-triggerer
3 minutes ago      Up About a minute   8080/tcp
```

5. Verificar os Logs (Airflow)

`docker compose logs airflow-init`

`docker compose logs airflow-apiserver`

`docker compose logs airflow-scheduler`

```

PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose logs airflow-init
.airflow-init | 2026-09-06T00:00:10.184684Z [info      ] Will assume transactional DDL. [alembic
.airflow-init | 2026-09-06T00:00:10.210976Z [info      ] Running stamp_revision -> 02ca36b0235b
.airflow-init | 2026-09-06T00:00:10.746514Z [info      ] FABDBManager tables have been created f
.airflow-init | 2026-09-06T00:00:12.308902Z [info      ] Database migration done!          [airflow
.airflow-init | 2026-09-06T00:00:23.171583Z [warning   ] starlette.middleware.wsgi is deprecated
.airflow-init | 2026-09-06T00:00:23.229783Z [warning   ] Using the in-memory storage for trackin
.airflow-init | Traceback (most recent call last):
.airflow-init |   File "/home/airflow/.local/bin/airflow", line 6, in <module>
.airflow-init |     sys.exit(main())
.airflow-init |         ~~~~~^
.airflow-init |   File "/home/airflow/.local/lib/python3.13/site-packages/airflow/__main__.py",
.airflow-init |     line 61, in main
.airflow-init |         args.func(args)
.airflow-init |         ~~~~~^
.airflow-init |   File "/home/airflow/.local/lib/python3.13/site-packages/airflow/cli/cli_conf
.airflow-init |     g.py", line 49, in command
.airflow-init |         return func(*args, **kwargs)
.airflow-init |   File "/home/airflow/.local/lib/python3.13/site-packages/airflow/utils/cli.py"
.airflow-init |     , line 113, in wrapper
.airflow-init |         return f(*args, **kwargs)
.airflow-init |   File "/home/airflow/.local/lib/python3.13/site-packages/airflow/utils/provide
.airflow-init |     rs_configuration_loader.py", line 54, in wrapped function

```



```

PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose logs airflow-apiserver


airflow-apiserver |
airflow-apiserver |
airflow-apiserver | _____
airflow-apiserver |  ____  |__(_)_____/_/_____/
airflow-apiserver |  ____ /| |__/_/_____/_____/_____\ | /| /|
airflow-apiserver |  ____ ____ | / / ____/_/_____/_____/_____/
airflow-apiserver |  _/_/_ |/_/_/_/_/_/_/_/_/_/_/_/_/_/_/_/_
airflow-apiserver | Running the API server with uvicorn:
airflow-apiserver | Apps: all
airflow-apiserver | Workers: 1
airflow-apiserver | Host: 0.0.0.0:8080
airflow-apiserver | Timeout: 120
airflow-apiserver | Logfiles: -
airflow-apiserver | =====
airflow-apiserver | 2026-09-06T00:02:06.717835Z [warning ] SimpleAuthManager is active but th
e deployment shape looks like production (non-sqlite backend, non-local API host, or a distribu
ted executor). SimpleAuthManager stores passwords in plaintext at /opt/airflow/simple_auth_mana
ger_passwords.json.generated and prints generated passwords to stdout/logs on first init. Use a
real auth manager (e.g. FAB or Keycloak) for production deployments. [airflow.api_fastapi.auth
.managers.simple.simple_auth_manager] loc=simple_auth_manager.py:176
airflow-apiserver | Simple auth manager | Password for user 'admin': NxPgAQDvNMRQ4UtZ
airflow-apiserver | 2026-09-06T00:02:17.220444Z [info      ] Started server process [8]      [uv
icorn.error] loc=server.py:94
airflow-apiserver | 2026-09-06T00:02:17.221028Z [info      ] Waiting for application startup. [
uvicorn.error] loc=on.py:48
airflow-apiserver | 2026-09-06T00:02:17.225031Z [info      ] Application startup complete. [uv
icorn.error] loc=on.py:62
airflow-apiserver | 2026-09-06T00:02:17.228304Z [info      ] Uvicorn running on http://0.0.0.0:
8080 (Press CTRL+C to quit) [uvicorn.error] loc=server.py:225

```

```
Problems Output Debug Console Terminal ... powershell - atividade_05
PS C:\Users\ferna\Documents\Github\EDB-022\atividade_05> docker compose logs airflow-scheduler
airflow-scheduler | 2026-09-06T00:01:59.00112Z [info] Worker starting up pid=34 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.036660Z [info] Worker starting up pid=38 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.101656Z [info] Worker starting up pid=39 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.188747Z [info] Worker starting up pid=41 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.128449Z [info] Worker starting up pid=40 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.217245Z [info] Worker starting up pid=42 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.237175Z [info] Worker starting up pid=43 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.270381Z [info] Worker starting up pid=44 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.281771Z [info] Worker starting up pid=45 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.296321Z [info] Worker starting up pid=46 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.340257Z [info] Worker starting up pid=47 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.343751Z [info] Worker starting up pid=48 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.376259Z [info] Worker starting up pid=49 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.409057Z [info] Worker starting up pid=50 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.479652Z [info] Worker starting up pid=51 [ai
rflow.executors.local_executor.LocalExecutor] loc=local_executor.py:76
airflow-scheduler | 2026-09-06T00:01:59.520428Z [info] Adopting or resetting orphaned tas
ks for active dag runs [airflow.jobs.scheduler_job_runner.SchedulerJobRunner] loc=scheduler_job
runner.py:3252
```


6. Abrir o Airflow

<http://localhost:8080/auth/login>



7. Criar DAG Teste

atividade_05_teste (Acionar)



8. Configurar Postgres no (docker-compose)

docker compose up -d pipeline-postgres

```
Problems Output Terminal ... powershell - atividade_05
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose config
name: atividade_05_default
volumes:
  pipeline_postgres_data:
    name: atividade_05_pipeline_postgres_data
  postgres_data:
    name: atividade_05_postgres_data
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose up -d pipeline-postgres
[+] up 18/18
✓ Image postgres:16 Pulled 183.2s
✓ Volume atividade_05_pipeline_postgres_data Created 2.4s
✓ Container eedb022-a5-postgres Started 16.2s
```

9. Preparar Banco de Dados

docker compose exec pipeline-postgres psql -U postgres -d eedb022_a5 -c "CREATE SCHEMA IF NOT EXISTS raw; CREATE SCHEMA IF NOT EXISTS trusted; CREATE SCHEMA IF NOT EXISTS delivery;"

docker compose exec pipeline-postgres psql -U postgres -d eedb022_a5 -c "\dn"

```
Problems Output Terminal ... powershell - atividade_05
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose exec pipeline-postgres psql -U postgres -d eedb022_a5 -c "CREATE SCHEMA IF NOT EXISTS raw; CREATE SCHEMA IF NOT EXISTS trusted; CREATE SCHEMA IF NOT EXISTS delivery;"
CREATE SCHEMA
PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> docker compose exec pipeline-postgres psql -U postgres -d eedb022_a5 -c "\dn"
List of schemas
  Name | Owner
-----+-----
 delivery | postgres
 public | pg_database_owner
 raw | postgres
 trusted | postgres
(4 rows)
```

10. Trazer os Scripts da Atividade 4

Invoke-WebRequest `

-Uri "https://github.com/LuccaTomazeli/eEDB-022/archive/refs/heads/main.zip" `

-OutFile ".\atividade_04_temp\eEDB-022-main.zip"

Expand-Archive `

-Path ".\atividade_04_temp\eEDB-022-main.zip" `

-DestinationPath ".\atividade_04_temp\extraido" `

-Force

```
Problems Output Terminal ... powershell - atividade_05 ⚠ + - [ ] [ ] ... | [ ] [ ] X

PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> Get-ChildItem .\atividade_04
e_04_temp\extraido\eEDB-022-main\atividade_04 -Recurse

Mode                LastWriteTime         Length Name
----                -
-a-----         26/08/2026      14:36      100024 trusted_bancos.parquet
-a-----         26/08/2026      14:36       4081 trusted_empregados.parquet
-a-----         26/08/2026      14:36       8930 trusted_reclamacoes.parquet

Diretório: C:\Users\ferna\Documents\Github\eEDB-022\atividade_05\atividade_04
_temp\extraido\eEDB-022-main\atividade_04\eedb022_dbt

Mode                LastWriteTime         Length Name
----                -
d-----         06/09/2026      11:36      macros
d-----         06/09/2026      11:36      models
-a-----         26/08/2026      14:36       135 dbt_project.yml

Diretório: C:\Users\ferna\Documents\Github\eEDB-022\atividade_05\atividade_04
_temp\extraido\eEDB-022-main\atividade_04\eedb022_dbt\macros

Mode                LastWriteTime         Length Name
----                -
-a-----         26/08/2026      14:36       213 generate_schema_name.sql
```

11. Copiar os Scripts (Atividade 4)

Copy-Item `

".\atividade_04_temp\extraido\eEDB-022-main\atividade_04\scripts*.py" `

".\scripts\" `

-Force

```
Problems Output Terminal ... powershell - atividade_05 + - [ ] [ ] ... | [ ] [ ] X
PS C:\Users\ferna\Documents\Github\eeDB-022\atividade_05> Get-ChildItem .\_atividade_04_temp\extraido\eeDB-022-main\atividade_04 -Recurse
PS C:\Users\ferna\Documents\Github\eeDB-022\atividade_05> Get-ChildItem .\scripts

Diretório: C:\Users\ferna\Documents\Github\eeDB-022\atividade_05\scripts

Mode                LastWriteTime         Length Name
----                -
-a-----         26/08/2026      14:36           968 depara_bcb.py
-a-----         26/08/2026      14:36           650 export_parquet.py
-a-----         26/08/2026      14:36          1690 ingest_raw.py
```

12. Copiar o Projeto DBT

Copy-Item`

```
".\_atividade_04_temp\extraido\eeDB-022-main\atividade_04\eedb022_dbt\*" `
".\dbt\" `
-Recurse `
-Force`
```

```
Problems Output Terminal ... powershell - atividade_05 + - [ ] [ ] ... | [ ] [ ] X
PS C:\Users\ferna\Documents\Github\eeDB-022\atividade_05> Get-ChildItem .\dbt -Recurse

Diretório: C:\Users\ferna\Documents\Github\eeDB-022\atividade_05\dbt\models

Mode                LastWriteTime         Length Name
----                -
-a-----         26/08/2026      14:36           533 delivery_final.sql
-a-----         26/08/2026      14:36           343 trusted_bancos.sql
-a-----         26/08/2026      14:36           291 trusted_empregados.sql
-a-----         26/08/2026      14:36           289 trusted_reclamacoes.sql
```

13. Adaptar conteúdo em 'scripts\ingest_raw.py'

De >> localhost:5433/eedb022_a4

Para >> pipeline-postgres:5432/eedb022_a5

```
ingest_raw.py 1, U X  README.md M ●
atividade_05 > scripts > ingest_raw.py > ...
1  from pyspark.sql import SparkSession
2  import os
3
4  JDBC_JAR = "/opt/atividade_05/jars/postgresql-42.7.4.jar"
5  ✨
6  PG_URL = "jdbc:postgresql://pipeline-postgres:5432/eedb022_a5"
7
8  PG_PROPS = {
9      "user": "postgres",
10     "password": "postgres",
11     "driver": "org.postgresql.Driver"
12 }
```

14. Criar pasta 'data\input' e três subpastas

New-Item -ItemType Directory -Force .\data\input

New-Item -ItemType Directory -Force .\data\input\Bancos

New-Item -ItemType Directory -Force .\data\input\Empregados

New-Item -ItemType Directory -Force .\data\input\Reclamacoes

```
Terminal  Output  ...  powershell - atividade_05 ⚠ + v □ 🗑 ... | 🔍 ✕

PS C:\Users\ferna\Documents\Github\eedb-022\atividade_05> New-Item -ItemType Directory -Force .\data\input

PS C:\Users\ferna\Documents\Github\eedb-022\atividade_05> New-Item -ItemType Directory -Force .\data\input\Bancos
>> New-Item -ItemType Directory -Force .\data\input\Empregados
● >> New-Item -ItemType Directory -Force .\data\input\Reclamacoes

Diretório: C:\Users\ferna\Documents\Github\eedb-022\atividade_05\data\input

Mode                LastWriteTime         Length Name
----                -
d-----           06/09/2026   12:01           Bancos
d-----           06/09/2026   12:01           Empregados
d-----           06/09/2026   12:01           Reclamacoes
```

15. Copiar os dados originais

- BANCOS

Copy-Item `

```
"C:\Users\ferna\Documents\Github\eEDB-022\Dados\Bancos\*" `
```

```
".\data\input\Bancos\" `
```

```
-Force
```

- EMPREGADOS

```
Copy-Item `
```

```
"C:\Users\ferna\Documents\Github\eEDB-022\Dados\Empregados\*" `
```

```
".\data\input\Empregados\" `
```

```
-Force
```

- FUNCIONARIOS


```
Copy-Item `
```

```
"C:\Users\ferna\Documents\Github\eEDB-022\Dados\Reclamacoes\*" `
```

```
".\data\input\Reclamacoes\" `
```

```
-Force
```

```
Get-ChildItem .\data\input -Recurse
```



The screenshot shows a PowerShell terminal window with the title "powershell - atividade_05". The command executed is `Get-ChildItem .\data\input -Recurse`. The output is a table listing the contents of the directory.

Mode	LastWriteTime	Length	Name
d-----	06/09/2026 12:06		Bancos
d-----	06/09/2026 12:06		Empregados
d-----	06/09/2026 12:06		Reclamacoes

16. Copiar o driver JDBC

```
New-Item -ItemType Directory -Force .\jars
```

```
Copy-Item `
```

```
".\atividade_04_temp\extraido\eEDB-022-main\atividade_04\jars\postgresql-42.7.4.jar" `
```


".\jars\"

-Force

Get-ChildItem .\jars

```
Terminal Output ... powershell - atividade_05

PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> Get-ChildItem .\jars
Diretório: C:\Users\ferna\Documents\Github\eEDB-022\atividade_05\jars

Mode                LastWriteTime         Length Name
----                -
-a-----         26/08/2026   14:36       1086687 postgresql-42.7.4.jar

PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05>
```


17. Atualizar o docker-compose alterando o 'airflow-scheduler'

- ./data:/opt/atividade_05/data
- ./scripts:/opt/atividade_05/scripts
- ./dbt:/opt/atividade_05/dbt
- ./jars:/opt/atividade_05/jars

```
ingest_raw.py 1, u x README.md M docker-compose.yml M
atividade_05 > docker-compose.yml
1  services:
37  airflow-init:
43  environment:
49      AIRFLOW__API_AUTH__JWT_SECRET: eEDB022Atividade05AirflowJWTSe
50  volumes:
51      - ./dags:/opt/airflow/dags
52      - ./logs:/opt/airflow/logs
53      - ./plugins:/opt/airflow/plugins
54      - ./config:/opt/airflow/config
55      - ./data:/opt/atividade_05/data
56      - ./scripts:/opt/atividade_05/scripts
57      - ./dbt:/opt/atividade_05/dbt
58      - ./jars:/opt/atividade_05/jars
59  command:
```

18. Criar arquivo 'Dockerfile'

-- atividade_05/Dockerfile

A screenshot of a code editor with a dark theme. The editor has several tabs at the top: 'ingest_raw.py 1, U', 'README.md M', and 'Dockerfile U'. The active tab is 'Dockerfile U'. The file path 'atividade_05 > Dockerfile > ...' is shown in the breadcrumb. The Dockerfile content is as follows:

```
1 FROM apache/airflow:3.3.1
2
3 USER root
4
5 # Instala Java para execução do PySpark
6 RUN apt-get update \
7     && apt-get install -y --no-install-recommends openjdk-17-jre-headless \
8     && apt-get clean \
9     && rm -rf /var/lib/apt/lists/*
10
11 ENV JAVA_HOME=/usr/lib/jvm/java-17-openjdk-amd64
12 ENV PATH="${JAVA_HOME}/bin:${PATH}"
13
14 USER airflow
```

19. Verificar versões: Java, PySpark, DBT e Great Expectations

docker compose exec airflow-scheduler java -version

docker compose exec airflow-scheduler python -c "import pyspark; print('PySpark:', pyspark.__version__)"

docker compose exec airflow-scheduler dbt --version

docker compose exec airflow-scheduler python -c "import great_expectations as gx; print('Great Expectations:', gx.__version__)"

```
Terminal Output ... powershell - atividade_05

PS C:\Users\ferna\Documents\Github\eeDB-022\atividade_05> docker compose ps
● er java -versionhub\eeDB-022\atividade_05>
openjdk version "17.0.20.1" 2026-08-18
OpenJDK Runtime Environment (build 17.0.20.1+1-1-deb12u1-Debian)
OpenJDK 64-Bit Server VM (build 17.0.20.1+1-1-deb12u1-Debian, mixed mode, sharing)
PS C:\Users\ferna\Documents\Github\eeDB-022\atividade_05> docker compose exec airfl
ow-scheduler python -c "import pyspark; print('PySpark:', pyspark.__version__)"
PySpark: 3.5.6
PS C:\Users\ferna\Documents\Github\eeDB-022\atividade_05> docker compose exec airfl
ow-scheduler dbt --version

Core:
- installed: 1.12.3
- latest: 1.12.3 - Up to date!

Plugins:
- postgres: 1.11.0 - Up to date!

PS C:\Users\ferna\Documents\Github\eeDB-022\atividade_05> docker compose exec airfl
ow-scheduler python -c "import great_expectations as gx; print('Great Expectations:
● ', gx.__version__)"
Great Expectations: 1.22.0
PS C:\Users\ferna\Documents\Github\eeDB-022\atividade_05>
```

20. Adaptar conteúdo em 'scripts\depara_bcb.py'

host = pipeline-postgres

port = 5432

database = eedb022_a5

```
① README.md ● depara_bcb.py 2, M X
atividade_05 > scripts > depara_bcb.py > ...
1  import requests
2  import psycopg2
3
4
5  URL_BCB = (
6      "https://olinda.bcb.gov.br/olinda/servico/BcBase/"
7      "versao/v2/odata/EntidadesSupervisionadas"
8      "(dataBase=@dataBase)?"
9      "@dataBase='12-31-2024'"
10     "&$top=10000"
11     "&$format=json"
12 )
13
14 PG_CONFIG = {
15     "host": "pipeline-postgres",
16     "port": 5432,
17     "user": "postgres",
18     "password": "postgres",
19     "dbname": "eedb022_a5",
20 }
```

21. Adaptar conteúdo em 'scripts\export_parquet.py'

trusted.trusted_bancos

trusted.trusted_reclamacoes

trusted.trusted_empregados

delivery.delivery_final

```
README.md • export_parquet.py 2, M X
atividade_05 > scripts > export_parquet.py > tabelas_trusted
21
22 os.makedirs(TRUSTED_DIR, exist_ok=True)
23 os.makedirs(DELIVERY_DIR, exist_ok=True)
24
25
26 engine = create_engine(PG_URL)
27
28
29 print("=====")
30 print("ATIVIDADE 5 - EXPORTAÇÃO PARQUET")
31 print("=====")
32
33 💡
34 tabelas_trusted = [
35     "trusted_bancos",
36     "trusted_reclamacoes",
37     "trusted_empregados"
38 ]
39
```

22. Criar o 'dbt\profiles.yml'

eedb022_dbt:

target: dev

outputs:

dev:

type: postgres

host: pipeline-postgres

user: postgres

password: postgres

port: 5432

dbname: eedb022_a5

schema: trusted

threads: 4

```
1 eedb022_dbt:
2   target: dev
3
4   outputs:
5     dev:
6       type: postgres
7       host: pipeline-postgres
8       user: postgres
9       password: postgres
10      port: 5432
11      dbname: eedb022_a5
12      schema: trusted
13      threads: 4
```

23. Criar o 'dbt\dbt_project.yml'

name: 'eedb022_dbt'

version: '1.0.0'

profile: 'eedb022_dbt'

model-paths:

- models

macro-paths:

- macros

models:

eedb022_dbt:

+materialized: table

```
① README.md ● ! profiles.yml u x ! dbt_project.yml ●
atividade_05 > dbt > ! dbt_project.yml
1  name: 'eedb022_dbt'
2  |
3  version: '1.0.0'
4  |
5  profile: 'eedb022_dbt'
6  |
7  model-paths:
8  |   - models
9  |
10 macro-paths:
11 |   - macros
12 |
13 models:
14   eedb022_dbt:
15     +materialized: table
```

24. Executar o 'scripts\ingest_raw.py'

python ingest_raw.py

```
Terminal  Output  Debug Console  ...  docker - atividade_05 ⚠ + v □ □ ... | ⌵ ✕

ow-scheduler bashithub\eEDB-022\atividade_05>
de clientes SCR,
Schema: Ano, Trimestre, Categoria, Tipo, CNPJ IF, Instituição financeira, Índice,
Quantidade de reclamações reguladas procedentes, Quantidade de reclamações regulada
s - outras, Quantidade de reclamações não reguladas, Quantidade total de reclamaçãoe
s, Quantidade total de clientes CCS e SCR, Quantidade de clientes CCS, Quantidade
de clientes SCR, _c14
Expected: _c14 but found:
CSV file: file:///opt/atividade_05/data/input/Reclamacoes/2021_tri_02.csv
[Stage 17:>
(0
=====
====
INGESTÃO RAW CONCLUÍDA!
=====
airflow@debe8ac5f1cc:/opt/atividade_05/scripts$ ;49R
```

25. Consultar tabelas criadas e registros no Postgres

SELECT

schemaname,

tablename

```
FROM pg_tables  
  
WHERE schemaname = 'raw'  
  
ORDER BY tablename;
```

```
Terminal Output Debug Console ... docker - atividade_05 ⚠ + ▾ 📄 🗑 ... | 🔍 ✕  
  
ow-scheduler bashithub\eEDB-022\atividade_05>  
Type "help" for help.  
  
eedb022_a5=# SELECT  
    schemaname,  
    tablename  
FROM pg_tables  
WHERE schemaname = 'raw'  
ORDER BY tablename;  
    schemaname | tablename  
-----+-----  
    raw        | bancos  
    raw        | empregados  
    raw        | reclamacoes  
(3 rows)
```

```
Terminal Output Debug Console ... docker - atividade_05 ⚠ + ▾ 📄 🗑 ... | 🔍 ✕  
  
ow-scheduler bashithub\eEDB-022\atividade_05>  
(3 rows)  
  
eedb022_a5=# SELECT COUNT(*) FROM raw.bancos;  
    count  
-----  
    1474  
(1 row)  
  
eedb022_a5=# SELECT COUNT(*) FROM raw.reclamacoes;  
    count  
-----  
    918  
(1 row)  
  
eedb022_a5=# SELECT COUNT(*) FROM raw.empregados;  
    count  
-----  
    34  
(1 row)
```

26. Executar o 'scripts\depara_bcb.py'

```
python depara_bcb.py
```



```
Terminal Output Debug Console ... docker - atividade_05
ow-scheduler bashithub\eEDB-022\atividade_05>
Tabela: raw.depara_bcb
=====
airflow@debe8ac5f1cc:/opt/atividade_05/scripts$ cd /opt/atividade_05/dbt
dbt run --profiles-dir .
20:01:50 Running with dbt=1.12.3
20:01:54 Registered adapter: postgres=1.11.0
20:02:02 Found 4 models, 478 macros
20:02:02
20:02:02 Concurrency: 4 threads (target='dev')
20:02:02
20:02:03 3 of 4 START sql table model trusted.trusted_reclamacoes .....
..... [RUN]
20:02:03 2 of 4 START sql table model trusted.trusted_empregados .....
..... [RUN]
20:02:03 1 of 4 START sql table model trusted.trusted_bancos .....
..... [RUN]
20:02:04 1 of 4 OK created sql table model trusted.trusted_bancos .....
..... [SELECT 1472 in 1.55s]
20:02:06 2 of 4 OK created sql table model trusted.trusted_empregados .....
..... [SELECT 32 in 3.05s]
20:02:06 3 of 4 OK created sql table model trusted.trusted_reclamacoes .....
..... [SELECT 437 in 3.07s]
20:02:06 4 of 4 START sql table model delivery.delivery_final .....
..... [RUN]
20:02:08 4 of 4 OK created sql table model delivery.delivery_final .....
..... [SELECT 1472 in 2.21s]
20:02:08
20:02:08 Finished running 4 table models in 0 hours 0 minutes and 6.62 seconds (6.62s).
20:02:09
20:02:09 Completed successfully
20:02:09
20:02:09 Done. PASS=4 WARN=0 ERROR=0 SKIP=0 NO-OP=0 REUSED=0 TOTAL=4
```

28. Exportar para Parquet 'scripts\export_parquet.py'

python export_parquet.py

```
Terminal Output ... docker - atividade_05 ⚠ + ▢ 🗑 ... | 🔍 ✕

rflow-scheduler bash:hub\eEDB-022\atividade_05>
airflow@debe8ac5f1cc:/opt/atividade_05/dbt$ cd /opt/atividade_05/scripts
python export_parquet.py

=====
ATIVIDADE 5 - EXPORTAÇÃO PARQUET
=====
Lendo trusted.trusted_bancos...
trusted_bancos: 1472 linhas exportadas
Lendo trusted.trusted_reclamacoes...
trusted_reclamacoes: 437 linhas exportadas
Lendo trusted.trusted_empregados...
trusted_empregados: 32 linhas exportadas
Lendo delivery.delivery_final...
delivery_final: 1472 linhas exportadas
=====
EXPORTAÇÃO PARQUET CONCLUÍDA!
=====
```

29. Criar/Executar Validação do Great Expectations

```
cd /opt/atividade_05/scripts
```

```
python quality_check.py
```

Terminal

Output ...

docker - atividade_05 ⚠ + ▢ 🗑 ... | 🔍 ✕

```
rflow-scheduler bashithub\eEDB-022\atividade_05>
python quality_check.py
```

```
=====
ATIVIDADE 5 - QUALIDADE DOS DADOS
=====
```

```
-----
TRUSTED_BANCOS
-----
```

```
Arquivo: /opt/atividade_05/data/trusted/trusted_bancos.parquet
```

```
Linhas: 1472
```

```
Calculating Metrics: 100%|██████████| 1/1 [00:00<00:00, 329.09it/s]
```

```
✓ Tabela possui pelo menos 1 registro
```

```
Calculating Metrics: 100%|██████████| 2/2 [00:00<00:00, 760.18it/s]
```

```
✓ Estrutura de colunas está correta
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 329.87it/s]
```

```
✓ CNPJ não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 406.30it/s]
```

```
✓ Nome completo não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 385.77it/s]
```

```
✓ Nome de busca não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 402.07it/s]
```

```
✓ Segmento não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 404.06it/s]
```

```
✓ CNPJ possui 8 dígitos
```

```
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 474.19it/s]
```

```
✓ Segmento pertence ao padrão S1-S5
```

Terminal

Output ...

docker - atividade_05 ⚠ + ▾ 🗑 ... | 🔍 ✕

```
rflow-scheduler bashithub\eEDB-022\atividade_05>
```

```
TRUSTED_RECLAMACOES
```

```
-----  
Arquivo: /opt/atividade_05/data/trusted/trusted_reclamacoes.parquet
```

```
Linhas: 437
```

```
Calculating Metrics: 100%|██████████| 1/1 [00:00<00:00, 648.77it/s]
```

```
✓ Tabela possui pelo menos 1 registro
```

```
Calculating Metrics: 100%|██████████| 2/2 [00:00<00:00, 166.46it/s]
```

```
✓ Estrutura de colunas está correta
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 399.56it/s]
```

```
✓ Ano não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 375.39it/s]
```

```
✓ Trimestre não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 1325.28it/s]
```

```
✓ CNPJ não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 380.11it/s]
```

```
✓ Instituição não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 216.46it/s]
```

```
✓ Quantidade de reclamações não possui valores nulos
```

```
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 269.33it/s]
```

```
✓ Ano está entre 2021 e 2022
```

```
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 122.29it/s]
```

```
✓ Trimestre possui valores válidos
```

```
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 436.73it/s]
```

```
✓ CNPJ possui 8 dígitos
```

```
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 292.29it/s]
```

```
✓ Quantidade de reclamações é positiva
```

```

Terminal Output
docker - atividade_05
rflow-scheduler bashithub\eEDB-022\atividade_05>
-----
TRUSTED_EMPREGADOS
-----
Arquivo: /opt/atividade_05/data/trusted/trusted_empregados.parquet
Linhas: 32
Calculating Metrics: 100%|██████████| 1/1 [00:00<00:00, 843.25it/s]
  ✓ Tabela possui pelo menos 1 registro
Calculating Metrics: 100%|██████████| 2/2 [00:00<00:00, 881.71it/s]
  ✓ Estrutura de colunas está correta
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 208.73it/s]
  ✓ Nome não possui valores nulos
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 1130.95it/s]
  ✓ Nota geral não possui valores nulos
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 383.61it/s]
  ✓ Nota de remuneração não possui valores nulos
Calculating Metrics: 100%|██████████| 6/6 [00:00<00:00, 1338.89it/s]
  ✓ Percentual de recomendação não possui valores nulos
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 509.75it/s]
  ✓ Nota geral está entre 0 e 5
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 409.38it/s]
  ✓ Nota de remuneração está entre 0 e 5
Calculating Metrics: 100%|██████████| 8/8 [00:00<00:00, 278.64it/s]
  ✓ Percentual de recomendação está entre 0 e 100

=====
RESULTADO FINAL DA QUALIDADE
=====
PASSOU: 28
FALHOU: 0

QUALIDADE DOS DADOS APROVADA!
Todas as validações foram executadas com sucesso.

```

30. Criar/Construir DAG 'atividade_05_pipeline.py'

atividade 05/dags/atividade 05 pipeline.py

```
atividade_05 > dags > atividade_05_pipeline.py > ...
1 from datetime import datetime
2
3 from airflow.sdk import DAG
4 from airflow.providers.standard.operators.bash import BashOperator
5
6
7 with DAG(
8     dag_id="pipeline_atividade_05",
9     start_date=datetime(2026, 1, 1),
10    schedule=None,
11    catchup=False,
12    tags=[
```

31. Disparar o Pipeline pelo Airflow (Orquestrador)

http://localhost:8080/dags/pipeline_atividade_05/tasks

Interface do Airflow para disparar o DAG `pipeline_atividade_05`.

Acionar Dag - pipeline_atividade_05

☒ Execução Única
Acionar uma única execução deste Dag

☐ Backfill
Executar este Dag para um intervalo de datas

Data Lógica: 06/09/2026 17:58:03

Opções Avançadas

Acionar

Nome da Tarefa	Estado	Operador	Índice	Mapeado
dbt_run	all_success	BashOperator	0	false
depara_bcb	all_success	BashOperator	0	false
export_parquet	all_success	BashOperator	0	false
ingest_raw	all_success	BashOperator	0	false
quality_check	all_success	BashOperator	0	false

ID da Tarefa	Índice do Mapa	Estado	Data Inicial	Número de Tentativas	Operador	Duração
export_parquet		Sucesso	2026-09-06 18:01:51	1	BatchOperator	00:00:04.696
quality_check		Sucesso	2026-09-06 18:01:27	1	BatchOperator	00:00:21.046
dbt_run		Sucesso	2026-09-06 18:01:05	1	BatchOperator	00:00:20.241
depara_bcb		Sucesso	2026-09-06 18:00:54	1	BatchOperator	00:00:08.731
ingest_raw		Sucesso	2026-09-06 17:59:19	1	BatchOperator	00:01:32

32. Realizar Download/Instalação e QuickStart do DataHub

pip install acryl-datahub

datahub docker quickstart



docker system df


```
Terminal Output Debug Console ... pip - atividade_05 + v [ ] [ ] ... | [ ] [ ] X

PS C:\Users\ferna\Documents\Github\eEDB-022\atividade_05> pip install acryl-data
hub
>> datahub docker quickstart
>> ``` @cite@turn@search1@
>> ...
Collecting annotated-types>=0.6.0
  Downloading annotated_types-0.8.0-py3-none-any.whl (13 kB)
Collecting pydantic-core==2.33.2
  Downloading pydantic_core-2.33.2-cp311-cp311-win_amd64.whl (2.0 MB)
  2.0/2.0 MB 4.0 MB/s eta 0:00:00
Collecting typing-inspection>=0.4.0
  Downloading typing_inspection-0.4.4-py3-none-any.whl (14 kB)
Collecting certifi
  Downloading certifi-2026.7.22-py3-none-any.whl (136 kB)
  137.0/137.0 kB 90.1 kB/s eta 0:00:00
Collecting mypy-extensions>=0.3.0
  Downloading mypy_extensions-1.1.0-py3-none-any.whl (5.0 kB)
Collecting httpcore==1.*
  Downloading httpcore-1.0.9-py3-none-any.whl (78 kB)
  78.8/78.8 kB 1.1 MB/s eta 0:00:00
Collecting h11>=0.16
  Downloading h11-0.16.0-py3-none-any.whl (37 kB)
Collecting charset-normalizer<4,>=2
  Downloading charset_normalizer-3.5.1-cp311-cp311-win_amd64.whl (206 kB)
  206.7/206.7 kB 2.5 MB/s eta 0:00:00
Installing collected packages: wrapt, win32-setctime, urllib3, typing_extensions,
, toml, tabulate, six, ruamel.yaml, rpds-py, PyYAML, pywin32, python-json-logger,
, pyreadline3, psutil, propcache, packaging, mypy-extensions, multidict, jsonref
, ijson, idna, h11, frozenlist, expandvars, cramjam, colorama, click-spinner, cl
ick, charset-normalizer, certifi, cached_property, avro, attrs, asgiref, annotat
ed-types, aiohappyeyeballs, yarl, typing-inspection, typing-inspect, sentry-sdk,
requests, referencing, python-utils, python-dateutil, pydantic-core, loguru, js
on-logic, humanfriendly, httpcore, Deprecated, click-default-group, avro-gen3, a
nyio, aiosignal, requests_file, pydantic, progressbar2, jsonschema-specification
s, httpx, docker, aiohttp, mixpanel, jsonschema, acryl-datahub
```


33. Acessar o DataHub

<http://localhost:9002/>



34. Cadastrar Fonte de Dados no DataHub

Menu >> Criar Fonte >> Postgres



35. Configuração da Fonte de Dados (Host Docker - Base Postgres)


Host: *host.docker.internal*

Port: *5433 (no Windows)*

Database: *eedb022_a5*


Username: *postgres*

Password: *postgres*



36. Testar conexão pelo DataHub

Opção >> Testar Conexão



37. DataHub - Definir nome da fonte de dados

PostgreSQL - eEDB-022 - Atividade 5

Conectar Fonte de Dados

✓ Escolher Fonte de Dados

✓ Configurar Conexão

—

✓ Agendamento de Sincron

4 Finalizar

Nome*

Dê um nome a esta fonte de dados

PostgreSQL - eEDB-022 - Atividade 5

Responsáveis

DataHub

✕ ▾

> Avançado

Anterior

Salvar

Salvar e Executar

38. DataHub - Executar o shedule

Executar

DataHub

Core

Início

Contexto

Documentos

Governança

Glossário

Tags

Domínios

Propriedades Estruturadas

Admin

Fontes de Dados

Analytics

Q Encontre tabelas, dashboards, pessoas e mais

≡ K

Descobrir →

Gerenciar Fontes de Dados

Configure e agende sincronizações para importar dados das suas fontes de dados

Sources

Histórico de Execuções

Segredos

Q Pesquisar...

Todos ▾

Atualizar


Nome ▾	Agendamento	Responsável	Última Execução	Status	
PostgreSQL - eEDB-022 - Atividade 5	-	DataHub	há 7 minutos	Em Execução	



39. DataHub - Verificar Tabelas Catalogadas

Pesquisar:

- *trusted_bancos*
- *trusted_empregados*
- *trusted_reclamacoes*
- *delivery_final*



DataHub Core

Encontre tabelas, dashboards, pessoas e mais

Platform (1) Última Modificação na Fonte

Documento pai Environment

Platform igual a PostgreSQL X + Adicionar filtro

Limpar Tudo

Tables Schemas

Exibindo 1 - 10 de 12 resultados

Navegar

- PostgreSQL 12
 - eedb022_a5 12
 - raw 4
 - trusted 3
 - delivery 1

delivery_final

Table | eedb022_a5 > delivery

bancos

Table | eedb022_a5 > raw

Resumo

delivery_final

Table | eedb022_a5 > delivery

Linhas	Colunas	Tamanho
1.5k linhas	7 colunas	238 KB

Documentação

Nenhuma documentação ainda.

Responsáveis

Nenhum responsável ainda.

Domínio

Nenhum domínio ainda.

Data Products

Nenhum produto ainda.

DataHub Core

trusted_bancos

trusted_bancos

Table | eedb022_a5 > trusted

Colunas 4 Documentação Lineage Propriedades Consultas Estatísticas Qualidade

Q. Pesquisar

Nome	Tipo	Descrição	Tags
cnpj	Anulável	String	
nome_completo	Anulável	String	
nome_busca	Anulável	String	
segmento	Anulável	String	

Resumo

trusted_bancos

Table | eedb022_a5 > trusted

Linhas	Colunas	Tamanho
1.5k linhas	4 colunas	336 KB

Documentação

Nenhuma documentação ainda.

Responsáveis

Nenhum responsável ainda.

Domínio

Nenhum domínio ainda.

Data Products

Nenhum produto ainda.

Tags

Nenhuma tag ainda.

Termos

Nenhum termo ainda.

Status

Sincronizado: há 1 hora de PostgreSQL

DataHub

Core

Q

Encontre tabelas, dashboards, pessoas e mais

K

Descobrir →

🏠

Início

Contexto

📁

Documentos

Governança

📖

Glossário

🏷️

Tags

🌐

Domínios

📋

Propriedades Estruturadas

Admin

🔗

Fontes de Dados

📊

Analytics

Conta

👤

Perfil

⚙️

Configurações

🔗

Recursos

trusted_empregados

Table | eedb022_a5 > trusted

Colunas 4

Documentação

Lineage

Propriedades

Consultas

Estatísticas

...

Q

Pesquisar

🕒

Nome	Tipo	Tags	Termos do Glossário
nome	Anulável String		
nota_geral	Anulável # Number		
nota_remuneracao	Anulável # Number		
pct_recomendam	Anulável # Number		

Resumo

trusted_empregados

Table | eedb022_a5 > trusted

Linhas

32 linhas

Colunas

4 colunas

Tamanho

16 KB

Documentação

Nenhuma documentação ainda.

Responsáveis

Nenhum responsável ainda.

Domínio

Nenhum domínio ainda.

Data Products

Nenhum produto ainda.

Tags

Nenhuma tag ainda.

Termos

Nenhum termo ainda.

Status

Sincronizado:

há 1 hora

de

PostgreSQL

Resumo

Lineage

Colunas

Propried...

trusted_reclamacoes

Table | eedb022_a5 > trusted

Colunas 5

Documentação

Lineage

Propriedades

Consultas

Estatísticas

...

Q

Pesquisar

🕒

Nome	Tipo	Tags	Termos do Glossário
ano	Anulável # Number		
trimestre	Anulável String		
cnpj	Anulável String		
instituicao	Anulável String		
qtd_reclamacoes	Anulável # Number		

Resumo

trusted_reclamacoes

Table | eedb022_a5 > trusted

Linhas

437 linhas

Colunas

5 colunas

Tamanho

74 KB

Documentação

Nenhuma documentação ainda.

Responsáveis

Nenhum responsável ainda.

Domínio

Nenhum domínio ainda.

Data Products

Nenhum produto ainda.

Tags

Nenhuma tag ainda.

Termos

Nenhum termo ainda.

Status

Sincronizado:

há 1 hora

de


PostgreSQL

Resumo

Lineage

Colunas

Propried...



40. Baixar e Extrair Camadas da Imagem de Ingestão

`docker pull acryldata/datahub-ingestion:v1.7.0`

```

Terminal Output Debug Console ... powershell - quickstart
PS C:\Users\ferna\.datahub\quickstart> docker pull acryldata/datahub-ingestion:v1.7.0
5f9555d00339: Pull complete
bd9ddc54bea9: Pull complete
30e6e440bc1e: Pull complete
966c395d29cb: Pull complete
3383059af3e8: Pull complete
4b9d36247971: Pull complete
0c28c7744bba: Pull complete
670e653e51a8: Pull complete
8b47791f8b35: Pull complete
244f35ac08d9: Pull complete
84881554cc75: Pull complete
4cad3db25491: Pull complete
00aa1a4db124: Pull complete
3fb4de96c0e9: Download complete
Digest: sha256:970282eb3b65bdc9d8da0084779b3cfdb37695063c2c9554d738c78ae02f21c5
Status: Downloaded newer image for acryldata/datahub-ingestion:v1.7.0
docker.io/acryldata/datahub-ingestion:v1.7.0
  
```

41. Criar Arquivo de Configuração 'dbt/datahub_dbt.yml'

`dbt\datahub_dbt.yml`

```
① README.md ● ! datahub_dbt.yml U X
atividade_05 > dbt > ! datahub_dbt.yml
1  source:
2    type: dbt
3    config:
4      manifest_path: /dbt/target/manifest.json
5      run_results_paths:
6      - /dbt/target/run_results.json
7      target_platform: postgres
8
9  sink:
10   type: datahub-rest
11   config:
12     server: http://host.docker.internal:8081
```

42. Testar Arquivo de Ingestão

`docker run --rm ``

`-v "C:\Users\ferna\Documents\Github\eEDB-022\atividade_05\dbt:/dbt" ``

`acryldata/datahub-ingestion:v1.7.0 ``

`ingest run -c /dbt/datahub_dbt.yml --dry-run``

15. Validações realizadas

Foi validado que:

- O PostgreSQL está disponível para o pipeline.
- O projeto dbt possui conexão válida com o banco.
- Os modelos dbt são executados sobre a camada trusted.
- Os metadados dbt são enviados ao DataHub.
- A lineage entre trusted_* e delivery_final foi registrada no DataHub.
- Os datasets PostgreSQL estão presentes no catálogo do DataHub.

16. Problemas/Dificuldades Enfrentadas

Durante a implementação foram encontrados alguns problemas de ambiente e integração:

- **DataHub e OpenSearch**

O DataHub apresentou instabilidade durante a recuperação do serviço de OpenSearch, incluindo períodos em que os índices ficaram indisponíveis ou em recuperação. Após a inicialização do OpenSearch, os índices voltaram a ser processados.

- **Índices do DataHub**

Foi identificado que os metadados dos modelos dbt permaneciam armazenados no GMS, mas alguns datasets dbt não estavam sendo retornados pelo índice de busca do OpenSearch. Isso dificultou a visualização dos ativos pela interface web.

- **Interface do DataHub**

Em alguns momentos a interface do DataHub (localhost:9002) apresentou carregamento lento, associado à alta utilização de CPU dos serviços, principalmente do Kafka, durante as atividades de recuperação e ingestão.

- **Airflow 3.3.1**

Houve dificuldade inicial para gerenciamento do usuário devido à utilização do SimpleAuthManager. A configuração encontrada indicava:

admin:admin

como usuário configurado, enquanto a senha era gerada e armazenada pelo próprio mecanismo de autenticação.

- **Comandos de ingestão DataHub**

Na tentativa de executar uma nova ingestão, foi necessário corrigir o diretório utilizado no volume Docker. O erro ocorreu porque o arquivo datahub_dbt.yml não estava disponível no caminho /dbt dentro do container.

- **Instabilidade de recursos**

Durante o laboratório, alguns serviços Docker apresentaram consumo elevado de CPU, principalmente o Kafka. Foi necessário monitorar os containers com docker stats e docker ps para identificar os serviços responsáveis pela lentidão.

17. Conclusão

A atividade 5 implementou um pipeline completo de engenharia de dados, integrando ingestão, tratamento, transformação, validação, exportação e catalogação.

O pipeline principal foi estruturado da seguinte forma:

Ingestão



RAW



De/Para



Trusted



Delivery



Quality Check



Parquet



DataHub

O fluxo utiliza Airflow para orquestração, PostgreSQL para persistência, dbt para transformação, Great Expectations para qualidade, Parquet para exportação e DataHub para catálogo e lineage, atendendo aos objetivos propostos para o laboratório.